

Assistente Virtual baseado em **GraphRAG + Fine-Tuning** para o diagnóstico da Toxoplasmose Congênita

Arthur Felipe Reis Souza

Orientador: Prof. Cristiano Leite de Castro

Belo Horizonte · 2026

● O QUÊ + POR QUÊ

Toxoplasmose congênita e a nossa proposta

Infecção pelo *Toxoplasma gondii* transmitida da gestante ao feto — o Brasil tem das **maiores incidências do mundo**.

O diagnóstico exige cruzar muitas variáveis:

- Sorologia materna (IgM / IgG / avidéz)
- Período gestacional
- Ultrassonografia fetal e neonatal
- PCR e análise de líquido

Heterogeneidade clínica — do recém-nascido assintomático às sequelas tardias graves. Expertise escassa na atenção primária, sob alta carga cognitiva e decisão sob pressão.

A PROPOSTA

Um assistente virtual que apoia o médico no diagnóstico da toxoplasmose congênita — **respostas fundamentadas, atualizadas e rastreáveis**, sem expor dados sensíveis do paciente.

- Fundamentado em diretrizes clínicas
- Conhecimento sempre atualizado
- Dados do hospital isolados da nuvem

Por que um LLM “puro” não basta — e o que fazemos

Aplicar GPT, LLaMA ou Gemini direto na medicina esbarra em quatro limitações críticas:

Alucinação

Afirmações fluentes, porém clinicamente incorretas.

Defasagem

Conhecimento congela na data de corte do treino.

Opacidade

Não expõe a fonte — sem rastreabilidade clínica.

LGPD

Prontuários não podem trafegar livres para a nuvem.

NOSSA RESPOSTA — TRÊS PILARES

◆ GraphRAG

Ancora cada resposta num grafo de conhecimento clínico (Neo4j) → mitiga alucinações.

▲ Fine-Tuning (LoRA)

Refina um LLaMA-3.1-8B com casos clínicos curados por médicos → vocabulário clínico.


■ Arquitetura segura

Backend orquestrador isola o hospital da nuvem e anonimiza antes da inferência.

● COMO FUNCIONA

Ontologia em grafo + pipeline GraphRAG/LoRA

O conhecimento clínico vira um *grafo de conhecimento* (Neo4j): entidades e relações explícitas extraídas das diretrizes.



1

NL → Cypher

A pergunta do médico vira query Cypher (LangChain) sobre o schema do grafo.

2

Retrieval do subgrafo

Neo4j retorna o subgrafo relevante, injetado no prompt aumentado.

3


Geração fundamentada

O LLM responde com hipótese, conduta e os IDs dos nós (rastreável).

Fine-Tuning · LoRA

Adaptadores de baixo rank sobre LLaMA-3.1-8B → alinhamento clínico viável em hardware limitado.

Três zonas de confiança — e o MVP já no ar



Demo ao vivo — IA-Toxo em ação



DEMO AO VIVO

Roteiro rápido

- 1 · Login na aplicação real
- 2 · Upload de uma diretriz clínica
- 3 · Pergunta sobre um caso de toxoplasmose congênita
- 4 · Resposta fundamentada e rastreável do assistente

mychatbotproject.uk

Veja na prática o fluxo completo: do upload do documento clínico à resposta do assistente, em produção.

● Ambiente real · não é mockup

O que entregamos e para onde vamos

36% → <12%

taxa de alucinação com recuperação estruturada

+14,3 p.p.

acurácia do GraphRAG vs. RAG vetorial

MVP no ar

full-stack em produção, pronto para demo

PRÓXIMOS PASSOS



Agora

MVP vetorial no ar

2

Próximo

GraphRAG sobre Neo4j

3

Depois

Fine-Tuning LoRA

4

Produção

K8s + Prometheus/Grafana

Conclusão Grafo de conhecimento + Fine-Tuning + isolamento de rede viabilizam **IA generativa segura, precisa e rastreável** em ecossistemas fechados de saúde.