

Arthur Felipe Reis Souza

**Desenvolvimento de um Assistente Virtual
Baseado em GraphRAG para Auxílio no
Diagnóstico de Toxoplasmose Congênita**

Belo Horizonte

2026

Arthur Felipe Reis Souza

Desenvolvimento de um Assistente Virtual Baseado em GraphRAG para Auxílio no Diagnóstico de Toxoplasmose Congênita

Monografia apresentada durante o Seminário dos Trabalhos de Conclusão do Curso de Graduação em Engenharia Elétrica da UFMG, como parte dos requisitos necessários à obtenção do título de Engenheiro Eletricista.

Universidade Federal de Minas Gerais – UFMG

Escola de Engenharia

Curso de Graduação em Engenharia Elétrica

Orientador: Prof. Cristiano Leite de Castro

Belo Horizonte

2026

*À criança que sonhava em ser cientista
e ao adulto que aprendeu a construir o futuro.*

Agradecimentos

Agradeço de coração à minha mãe, Denise, e aos meus irmãos, Marcio, Marco e Ana Flavia, por sempre me apoiarem e serem a minha base.

Agradeço também à todas as pessoas próximas e amigos que fizeram parte da minha história e me ajudaram a chegar até aqui.

*“A inteligência artificial não precisa ser fria e impessoal.
Ela pode ser a ferramenta mais poderosa que já criamos
para entender e melhorar a condição humana.”
(Fei-Fei Li)*

Resumo

O diagnóstico da toxoplasmose congênita é um processo clínico desafiador que exige a análise rigorosa de variáveis temporais e patológicas, como exames sorológicos e achados ultrassonográficos. O uso de Large Language Models (LLMs) na medicina, embora promissor, enfrenta obstáculos relacionados à imprecisão (alucinações do modelo) e à necessidade de isolamento de dados sensíveis. Sendo assim, este trabalho de conclusão tem como objetivo desenvolver uma arquitetura de chatbot baseado nas técnicas de *Fine-Tuning* e *Graph Retrieval-Augmented Generation* (GraphRAG) para auxiliar médicos e enfermeiros. A metodologia engloba a estruturação de uma ontologia médica em um banco de dados orientado a grafos (Neo4j) e a concepção de uma topologia de rede segura, que irá restringir o acesso de forma a proteger a rede interna do sistema como também os clientes. O sistema utiliza um servidor *backend* intermediário atuando como orquestrador, isolando a rede hospitalar dos ambientes de inferência de modelos hospedados em nuvem. Como resultados, nota-se que a orquestração via GraphRAG aumenta a acurácia e a explicabilidade dos resultados gerados, mitigando riscos clínicos ao fundamentar as respostas estritamente na literatura médica validada no grafo. Conclui-se que a separação arquitetural, aliada a bases de dados relacionais avançadas e técnicas de refinamento de modelo, viabiliza o uso da IA generativa de forma segura e eficiente nos ecossistemas fechados de saúde.

Palavras-chave: toxoplasmose congênita. inteligência artificial. GraphRAG. banco de dados em grafos. segurança da informação.

Abstract

The diagnosis of congenital toxoplasmosis is a challenging clinical process that requires rigorous analysis of temporal and pathological variables, such as serological tests and ultrasound findings. The use of Large Language Models (LLMs) in medicine, while promising, faces obstacles related to inaccuracy (model hallucinations) and the need to isolate sensitive data. Therefore, this final graduation project aims to develop a chatbot architecture based on Fine-Tuning and Graph Retrieval-Augmented Generation (GraphRAG) techniques to assist doctors and nurses in decision support. The methodology includes structuring a medical ontology in a graph database (Neo4j) and designing a secure network topology, aiming to restrict access to protect the system's internal infrastructure and user privacy. The system uses an intermediary backend server acting as an orchestrator, isolating the hospital network from cloud-hosted model inference environments. As a result, it is observed that GraphRAG orchestration increases the accuracy and explainability of the generated outcomes, mitigating clinical risks by grounding responses strictly in validated medical literature within the graph. It is concluded that architectural separation, combined with advanced relational databases and refinement techniques, enables the secure and efficient use of generative AI in closed healthcare ecosystems.

Key-words: congenital toxoplasmosis. artificial intelligence. GraphRAG. graph databases. information security.

Lista de ilustrações

Figura 1 – As três etapas para a criação de um LLM de alta qualidade: pré-treinamento, refinamento supervisionado e ajuste por preferências. . . .	27
Figura 2 – Comparação entre <i>full fine-tuning</i> e <i>Low-Rank Adaptation</i> (LoRA). No <i>full fine-tuning</i> , todos os pesos do modelo são atualizados durante o treinamento. No LoRA, apenas uma representação reduzida (de baixo <i>rank</i>) é atualizada, enquanto a matriz original permanece congelada. . .	28
Figura 3 – Forma canônica de um <i>pipeline</i> RAG. A pergunta do usuário aciona uma etapa de recuperação que consulta a fonte de dados externa e, em seguida, uma etapa de geração condicionada (<i>grounded generation</i>) pelo LLM.	29
Figura 4 – Pipeline de RAG por similaridade de <i>embeddings</i> . A pergunta é convertida em vetor por um modelo de <i>embedding</i> , comparada aos vetores armazenados no banco e os trechos mais similares são adicionados ao <i>prompt</i> antes da geração pelo LLM.	30

Lista de tabelas

Lista de abreviaturas e siglas

API	Application Programming Interface
HF	Hugging Face
IA	Inteligência Artificial
LLM	Large Language Model
RAG	Retrieval-Augmented Generation
REST	Representational State Transfer
UI	User Interface
VNet	Virtual Network
VPS	Virtual Private Server

Lista de símbolos

G	Símbolo placeholder
-----	---------------------

Sumário

1	INTRODUÇÃO	21
1.1	Contextualização e Justificativa	21
1.2	Definição do Problema	21
1.3	Objetivos	22
1.3.1	Objetivo Geral	22
1.3.2	Objetivos Específicos	22
1.4	Estrutura Geral do Trabalho	23
2	REVISÃO BIBLIOGRÁFICA	25
2.1	Toxoplasmose Congênita: Caracterização do Problema Clínico	25
2.2	Modelos de Linguagem de Grande Porte e suas Limitações em Saúde	26
2.3	Fine-Tuning: Adaptação Supervisionada de Modelos de Linguagem	26
2.3.1	As Três Etapas de Treinamento de um LLM	26
2.3.2	Full Fine-Tuning e Métodos Parameter-Efficient (PEFT / LoRA)	27
2.3.3	Papel do Fine-Tuning no IA-Toxo	28
2.4	Retrieval-Augmented Generation (RAG)	29
2.4.1	Conceito Geral	29
2.4.2	Pipeline de Recuperação por <i>Embeddings</i>	30
2.4.3	Limitações do RAG Vetorial	31
2.5	GraphRAG: Conhecimento Estruturado em Grafos	31
2.6	Bancos de Dados Orientados a Grafos e o Neo4j	31
2.7	Trabalhos Correlatos	32
2.8	Síntese da Revisão	32
3	METODOLOGIA	35
3.1	Visão Geral da Arquitetura do Sistema	35
3.2	Construção da Ontologia Médica e do Grafo de Conhecimento	36
3.2.1	Definição das Entidades e Relacionamentos	36
3.2.2	Implementação no Neo4j	37
3.3	Pipeline GraphRAG: Recuperação e Geração	38
3.3.1	Tradução de Consultas para Cypher via LangChain	38
3.3.2	Recuperação de Subgrafos e Enriquecimento do Prompt	38
3.3.3	Geração da Resposta pelo Modelo de Linguagem	39
3.4	Adaptação do Modelo de Linguagem com Fine-Tuning e LoRA	39
3.4.1	Seleção do Modelo Base	39
3.4.2	Curação do Conjunto de Dados de Fine-Tuning	40

3.4.3	Configuração do LoRA e Procedimento de Treinamento	40
3.5	Topologia de Rede e Segurança	41
3.5.1	Zonas de Proteção e Isolamento de Sub-redes	41
3.5.2	Servidor Backend como Orquestrador	41
3.6	Implantação em Kubernetes e Monitoramento	41
3.6.1	Configuração do Cluster Kubernetes	42
3.6.2	Monitoramento com Prometheus e Grafana	42
3.7	Protocolo de Avaliação do Sistema	43
4	RESULTADOS E DISCUSSÃO	45
4.1	Seção 3.1	45
4.2	Seção 3.2	45
5	CONCLUSÕES	47
5.1	Seção 4.1	47
5.2	Seção 4.2	47
	REFERÊNCIAS	49

1 Introdução

1.1 Contextualização e Justificativa

A integração de sistemas baseados em Inteligência Artificial (IA) no ambiente hospitalar tem transformado as metodologias de suporte à tomada de decisão, oferecendo ferramentas avançadas que processam um grande volume de dados e retornam uma resposta. Neste caso, o diagnóstico da toxoplasmose congênita traz grandes desafios, pois identificar precisamente essa patologia exige a relação de variáveis temporais e clínicas, como a análise de perfis sorológicos maternos (testes de avididade, níveis de IgG e IgM), o período gestacional e também a interpretação de exames complexos, como o de ultrassonografia. Para médicos e enfermeiros, processar todos esses dados relacionais com diretrizes médicas atualizadas, frequentemente sob a pressão do fluxo hospitalar, é uma tarefa demandante e de alta exigência cognitiva.

O desenvolvimento de sistemas de engenharia aplicados à saúde exige não apenas precisão algorítmica, precisa também infraestruturas que garantam a segurança dos dados, respeitando rigorosos fluxos de trabalho clínicos e normas de privacidade. Tradicionalmente, Large Language Models (LLMs) apresentam os riscos de cometer "alucinações", que é quando o modelo gera orientações plausíveis, porém que são clinicamente imprecisas. Para mitigar esse risco de alucinações e justificar a viabilidade técnica e científica de um assistente virtual médico, é necessário a construção de uma arquitetura robusta que ligue o raciocínio do modelo em bases de conhecimento determinísticas e estruturadas dentro de uma rede privada.

1.2 Definição do Problema

O problema central abordado neste trabalho se dá na limitação das técnicas tradicionais de recuperar informações complexas, como o *Retrieval-Augmented Generation* (RAG) que faz a busca de informações linearmente nas bases de dados comumente chamadas de *embedding databases*. Outro obstáculo se dá em mapear e recuperar adequadamente as conexões causais e temporais no diagnóstico da toxoplasmose congênita. A questão principal deste trabalho é: como arquitetar e desenvolver um sistema de *chatbot* que compreenda a complexa ontologia dessa doença utilizando técnicas de Deep Learning como *graphRAG* e *Fine-Tuning*, ao mesmo tempo em que garante o isolamento seguro entre a rede hospitalar e os ambientes de inferência de IA em nuvem?

Para solucionar essa lacuna técnica, este trabalho propõe a implementação de uma

arquitetura de chatbot baseada na integração das técnicas de *Graph Retrieval-Augmented Generation* (GraphRAG) e *Fine-Tuning*. Através da modelagem da base de dados do conhecimento clínico em um banco de dados orientado a grafos (Neo4j), o sistema torna-se capaz de mapear explicitamente as ligações entre sintomas, testes laboratoriais e intervenções terapêuticas. A solução projetada utiliza um servidor *backend* intermediário que atua como orquestrador, isolando a rede hospitalar dos ecossistemas de modelos hospedados em nuvem, que são protegida por firewalls e serviços de restrições de redes, assegurando a proteção de dados sensíveis e a acurácia do contexto injetado nas requisições.

1.3 Objetivos

Os objetivos deste trabalho estão divididos de forma a guiar o desenvolvimento e a avaliação do software proposto.

1.3.1 Objetivo Geral

Desenvolver um sistema de *chatbot* orquestrado por uma arquitetura GraphRAG com Fine-tuning para auxiliar profissionais de saúde (médicos e enfermeiros) no processo de diagnóstico da toxoplasmose congênita, garantindo a precisão da informação e a segurança da infraestrutura de rede.

1.3.2 Objetivos Específicos

- Projetar uma topologia de rede segura, estabelecendo zonas de proteção e regras de sub-redes para mediar a comunicação entre o ambiente hospitalar, o servidor *frontend/backend* e a nuvem.
- Modelar uma ontologia clínica para a toxoplasmose congênita e estruturá-la em um banco de dados em grafos (Neo4j).
- Realizar o refinamento do modelo usando uma base de dados propriamente curada e refinada de diagnósticos da doença.
- Desenvolver uma API *backend* responsável por receber o *prompt* inicial, executar o *retrieval* no banco de grafos e construir o *prompt* aumentado.
- Integrar a infraestrutura de orquestração com serviços de inferência de LLMs em nuvem, garantindo a sanitização e o fluxo adequado dos dados.
- Desenvolver uma interface *frontend* otimizada para a interação e visualização de dados por parte dos profissionais clínicos.

1.4 Estrutura Geral do Trabalho

Para atingir os objetivos propostos de forma clara e progressiva, esta monografia está estruturada em seis capítulos. O Capítulo 2 apresenta a Revisão de Literatura, analisando o estado da arte referente a arquiteturas RAG, bancos de dados em grafos e a aplicação de IA em fluxos de diagnóstico médico. O Capítulo 3 descreve os Materiais e Métodos, detalhando a engenharia de *software* e *hardware*, o modelo do banco Neo4j, como realizar a técnica de Fine-Tuning do modelo e também as políticas de segurança de rede e a integração de APIs. O Capítulo 4 expõe os Resultados, relatando o comportamento do sistema e o desempenho do modelo na geração de diagnósticos utilizando métricas nebulosas (métricas Fuzzy). O Capítulo 5 traz a Discussão, promovendo uma análise crítica da arquitetura proposta frente às soluções tradicionais de mercado. Finalmente, o Capítulo 6 apresenta a Conclusão do estudo, destacando as contribuições obtidas e sugerindo evoluções futuras para o projeto.

2 Revisão Bibliográfica

Este capítulo apresenta os fundamentos teóricos que sustentam o desenvolvimento do sistema de chatbot para diagnóstico da toxoplasmose congênita. A revisão é organizada de forma incremental: parte-se de uma caracterização sucinta do problema clínico — a toxoplasmose congênita — e dos limites atuais do uso de Large Language Models na área da saúde, e segue-se com a apresentação detalhada das duas técnicas centrais empregadas neste trabalho: o *Fine-Tuning* e o *Retrieval-Augmented Generation* (RAG). Após isso, discute-se a extensão do RAG para representações estruturadas dos dados através de relações entre nós (GraphRAG), e os principais trabalhos correlatos identificados na literatura. As ilustrações utilizadas nas seções de *Fine-Tuning* e RAG foram adaptadas do livro *Hands-On Large Language Models*, de [Alammar e Grootendorst \(2024\)](#), referência adotada como base conceitual para essas técnicas.

2.1 Toxoplasmose Congênita: Caracterização do Problema Clínico

A toxoplasmose é uma doença infecciosa de distribuição mundial, causada pelo protozoário *Toxoplasma gondii*. Quando uma gestante adquire a infecção durante o período da gravidez, há risco de transmissão vertical para o feto, configurando o quadro de toxoplasmose congênita. No Brasil, país de clima tropical e fácil propagação do protozoário, há muitos casos apresentando a forma congênita da doença, esse índice elevado coloca o país em posição de destaque no cenário global da enfermidade.

A heterogeneidade das manifestações clínicas é o aspecto mais desafiador do manejo da doença. Recém-nascidos infectados podem se apresentar assintomáticos ao nascimento e, ainda assim, desenvolver sequelas tardias graves, como perda visual progressiva por retinocoroidite recidivante, atraso no desenvolvimento motor ou crises convulsivas. Outros pacientes manifestam, já no período neonatal, a téttrade de Sabin (hidrocefalia, calcificações intracranianas, retinocoroidite e perturbações neurológicas).

A confirmação diagnóstica exige a interpretação articulada de testes sorológicos (IgM, IgG e teste de avididade de IgG), pesquisa direta do parasita por PCR, exames de imagem fetal e neonatal e, em alguns casos, análise de líquido. A integração desses dados em uma decisão terapêutica fundamentada demanda conhecimento atualizado das diretrizes, como também experiência prévia com a doença — recursos frequentemente escassos no contexto da atenção primária brasileira. Sendo assim, nesse cenário de complexidade e desigualdade no acesso à expertise médica que se justifica o desenvolvimento de ferramentas computacionais de apoio ao diagnóstico dessa doença.

2.2 Modelos de Linguagem de Grande Porte e suas Limitações em Saúde

A última década consolidou a arquitetura *Transformer* como paradigma dominante no processamento de linguagem natural e redes neurais artificiais. Modelos como GPT, LLaMA, Gemini e Claude — denominados *Large Language Models* (LLMs) — são treinados sobre grandes volume textuais e aprendem a prever, dada uma sequência de *tokens*, o *token* mais provável a seguir. Essa capacidade preditiva, quando escalada para bilhões de parâmetros, dá origem a sistemas capazes de gerar texto coerente, responder perguntas e estabelecer raciocínios em múltiplas etapas.

A aplicação direta de LLMs no domínio da saúde, contudo, tem três limitações principais. A primeira é o fenômeno comumente chamado de *alucinação*: a geração de afirmações fluentes e plausíveis, porém factualmente incorretas. Em medicina, uma informação equivocada pode resultar em conduta clínica inadequada, o que é inaceitável. A segunda é a defasagem temporal: o conhecimento embutido no modelo reflete apenas os dados disponíveis até a data de corte do treinamento, ignorando atualizações posteriores das diretrizes clínicas. A terceira é a opacidade quanto às fontes da resposta gerada, o que dificulta a rastreabilidade exigida por contextos médicos.

Para mitigar essas fragilidades, duas estratégias têm se consolidado como soluções complementares: o refinamento supervisionado (*Fine-Tuning*), que adapta o próprio modelo a um domínio específico, e a geração aumentada por recuperação (*Retrieval-Augmented Generation*, RAG), que injeta contexto factual no *prompt* a partir de uma base de conhecimento externa. Essas duas técnicas constituem o núcleo conceitual deste trabalho e são detalhadas nas próximas seções.

2.3 Fine-Tuning: Adaptação Supervisionada de Modelos de Linguagem

O *Fine-Tuning* é o processo de prosseguir o treinamento de um LLM previamente treinado, utilizando agora um conjunto de dados específico do domínio de interesse. Ao invés de aprender a língua do zero, parte-se de um modelo que já domina padrões gerais de linguagem e refina-se sua distribuição estatística para favorecer respostas no estilo, vocabulário e formato esperados pela aplicação alvo.

2.3.1 As Três Etapas de Treinamento de um LLM

Segundo [Alammar e Grootendorst \(2024\)](#), a construção de um LLM de alta qualidade percorre, tipicamente, três etapas sucessivas, ilustradas na Figura 1.




Figura 1 – As três etapas para a criação de um LLM de alta qualidade: pré-treinamento, refinamento supervisionado e ajuste por preferências.

Fonte: adaptado de [Alammar e Grootendorst \(2024\)](#).

A primeira etapa, denominada *modelagem de linguagem* ou pré-treinamento, é auto-supervisionada: o modelo aprende a prever o próximo *token* a partir de bilhões de palavras coletadas em fontes públicas e na web. O artefato gerado é chamado de modelo *base*, capaz de completar texto, mas pouco hábil e autônomo para seguir instruções. A segunda etapa, denominada *supervised fine-tuning* (SFT), utiliza um conjunto curado de pares no formato *[instrução, resposta esperada]* para ensinar o modelo a responder de forma alinhada às solicitações de um usuário; o resultado é um modelo dito *instruction-tuned*. A terceira etapa, opcional, é o *preference tuning*, em que o modelo é ajustado a partir de avaliações comparativas de qualidade — humanas ou geradas por outro modelo — para refinar tom, segurança e adequação das respostas.

Para o sistema desenvolvido neste trabalho, a etapa de pré-treinamento não é realizada localmente: parte-se de um modelo *base* já disponível publicamente. O esforço de adaptação concentra-se na segunda etapa, em que pares *[caso clínico, diagnóstico ou conduta esperada]*, elaborados pela equipe médica de curadoria, são empregados para alinhar o modelo ao registro discursivo da medicina e ao formato de resposta desejado pelo profissional de saúde.

2.3.2 Full Fine-Tuning e Métodos Parameter-Efficient (PEFT / LoRA)

Quando o refinamento atualiza todos os parâmetros do modelo, fala-se em *full fine-tuning*. Essa modalidade tende a oferecer o melhor desempenho, mas é cara pois exige memória de GPU proporcional ao tamanho do modelo, longo tempo de treinamento e armazenamento integral dos pesos atualizados a cada novo domínio ([ALAMMAR; GROOTENDORST, 2024](#)). Enfatizando que é impossível realizar o treinamento de uma rede neural profunda, principalmente large language models, localmente.

Como alternativa, o paradigma *Parameter-Efficient Fine-Tuning* (PEFT) propõe atualizar apenas um subconjunto reduzido de parâmetros, mantendo a maior parte dos pesos originais congelada. A técnica mais difundida desse paradigma é o *Low-Rank Adaptation* (LoRA), proposto por [Hu et al. \(2021\)](#) e cuja ideia central é representada na Figura 2: em vez de atualizar a matriz de pesos completa, decompõe-se a variação induzida pelo

refinamento em duas matrizes de baixa dimensionalidade (*low-rank*), que são as únicas atualizadas durante o treinamento. Ao final, as matrizes pequenas são combinadas aos pesos originais para gerar o modelo adaptado.




Figura 2 – Comparação entre *full fine-tuning* e *Low-Rank Adaptation* (LoRA). No *full fine-tuning*, todos os pesos do modelo são atualizados durante o treinamento. No LoRA, apenas uma representação reduzida (de baixo *rank*) é atualizada, enquanto a matriz original permanece congelada.

Fonte: adaptado de [Alammar e Grootendorst \(2024\)](#).

A escolha do LoRA neste trabalho deriva de três vantagens concretas. Primeiro, a redução drástica do número de parâmetros treináveis — frequentemente para menos de 1% do total — viabiliza o refinamento em GPUs únicas com memória moderada. Segundo, como apenas as matrizes de baixo *rank* precisam ser armazenadas, é possível manter múltiplos adaptadores especializados (por exemplo, um para diagnóstico de toxoplasmose congênita, outro para outra doença) sem duplicar o modelo base. Terceiro, a qualidade obtida costuma ser próxima à do *full fine-tuning* para tarefas de adaptação de domínio, justificando a relação custo-benefício ([HU et al., 2021](#); [ALAMMAR](#); [GROOTENDORST, 2024](#)).

Variantes mais recentes, como o QLoRA ([DETTMERS et al., 2023](#)), combinam LoRA com técnicas de quantização (representação dos pesos com menor precisão numérica) para reduzir ainda mais o consumo de memória, ampliando a viabilidade prática do refinamento em ambientes acadêmicos e hospitalares.

2.3.3 Papel do Fine-Tuning no IA-Toxo

Para o sistema proposto, o refinamento desempenha dois papéis. Primeiro, alinha o modelo ao registro discursivo da medicina, familiarizando-o com terminologias específi-

cas como “perfil sorológico reagente”, “avidez fraca”, “calcificações periventriculares” ou “retinocoroidite cicatrizada”. Segundo, ensina o modelo a estruturar a resposta no formato esperado pelo profissional de saúde, com hipótese diagnóstica clara, justificativa baseada nos exames apresentados e sugestão de conduta consistente com os protocolos brasileiros e internacionais. Ainda assim, o refinamento isolado não elimina o risco de alucinação para fatos específicos, motivo pelo qual ele é combinado com a recuperação aumentada, descrita a seguir.

2.4 Retrieval-Augmented Generation (RAG)

Mesmo quando refinado, um LLM permanece suscetível a alucinações em consultas que exigem conhecimento factual preciso ou recém-atualizado. O *Retrieval-Augmented Generation* (RAG), proposto por Lewis et al. (2020), foi concebido para mitigar essa limitação ao acoplar ao componente generativo um mecanismo de *recuperação* de informação a partir de uma base de conhecimento externa, mantida fora dos parâmetros do modelo.

2.4.1 Conceito Geral

A Figura 3 apresenta a forma canônica de um *pipeline* RAG. Diante de uma pergunta do usuário, o sistema executa duas etapas: (i) recupera, a partir de uma fonte de dados externa, trechos de informação relevantes para a pergunta; (ii) submete ao LLM um *prompt* composto pela pergunta original e pelo contexto recuperado, solicitando que a resposta seja *grounded*, isto é, fundamentada nesse contexto (ALAMMAR; GROOTENDORST, 2024).




Figura 3 – Forma canônica de um *pipeline* RAG. A pergunta do usuário aciona uma etapa de recuperação que consulta a fonte de dados externa e, em seguida, uma etapa de geração condicionada (*grounded generation*) pelo LLM.

Fonte: adaptado de Alammar e Grootendorst (2024).

Esse arranjo proporciona três benefícios diretos. Primeiro, reduz alucinações ao restringir a geração ao conteúdo efetivamente presente nos documentos recuperados. Segundo, permite atualizar o conhecimento do sistema sem retrainar o modelo: basta atua-

lizar a base. Terceiro, viabiliza a rastreabilidade das respostas, pois cada afirmação pode ser remetida ao trecho recuperado que a sustenta — propriedade especialmente valiosa em medicina (LEWIS et al., 2020).

2.4.2 Pipeline de Recuperação por *Embeddings*

A implementação mais difundida do RAG utiliza recuperação por similaridade vetorial (ALAMMAR; GROOTENDORST, 2024). O processo é apresentado na Figura 4. Antes da operação, os documentos da base de conhecimento são fragmentados em trechos (*chunks*) e convertidos em vetores densos por um modelo de *embedding*, sendo armazenados em um banco vetorial. Em tempo de consulta, o *prompt* do usuário é igualmente convertido em *embedding* e comparado, por meio de uma métrica de similaridade (tipicamente o cosseno), aos vetores da base; os trechos mais próximos são selecionados como contexto relevante. O *prompt* é então enriquecido com esse contexto (*updated prompt*) e enviado ao LLM, que gera a resposta condicionada.




Figura 4 – Pipeline de RAG por similaridade de *embeddings*. A pergunta é convertida em vetor por um modelo de *embedding*, comparada aos vetores armazenados no banco e os trechos mais similares são adicionados ao *prompt* antes da geração pelo LLM.

Fonte: adaptado de Alammar e Grootendorst (2024).

Esse fluxo introduz três parâmetros de projeto relevantes: o tamanho dos *chunks* (que afeta a granularidade do contexto recuperado), o modelo de *embedding* (que determina a qualidade da similaridade semântica) e o número de trechos retornados (*top-k*, que regula a relação entre cobertura e ruído). Esses parâmetros são configuráveis na rede e podem ter um valor ótimo de acordo com uma métrica específica, porém quando configurados inadequadamente são causa frequente de respostas insatisfatórias.

2.4.3 Limitações do RAG Vetorial

Apesar de eficaz em muitos cenários, a recuperação de dados por LLMs através de vectordatabases apresenta limitações importantes quando aplicada a domínios cujo conhecimento é predominantemente *relacional*. A similaridade entre *embeddings* captura proximidade semântica entre trechos, mas tende a perder relações estruturais explícitas, como dependências causais, sequências temporais e hierarquias entre conceitos. No diagnóstico da toxoplasmose congênita, em que o raciocínio clínico depende fortemente da articulação entre múltiplos eixos (sorologia materna, idade gestacional, achados no recém-nascido, evolução clínica), essa perda de estrutura representa uma desvantagem significativa.

A próxima seção descreve a evolução do RAG que aborda essa limitação ao substituir o repositório vetorial por uma representação em grafo.

2.5 GraphRAG: Conhecimento Estruturado em Grafos

O GraphRAG é uma extensão do paradigma de geração aumentada que substitui (ou complementa) o repositório vetorial por uma representação estruturada do conhecimento em grafos. Nessa abordagem, o conhecimento é organizado como uma rede de entidades conectadas por relações semânticas explícitas. Em vez de buscar trechos textuais similares, o mecanismo de recuperação percorre o grafo seguindo arestas relevantes, retornando subgrafos contextualmente conectados à consulta.

Quando aplicado ao domínio clínico da toxoplasmose congênita, o GraphRAG permite representar formalmente entidades como *IgG materna*, *IgM neonatal*, *idade gestacional*, *calcificações cerebrais*, *retinocoroidite ativa* e *sulfadiazina*, conectando-as por relações como *indica*, *contraindica*, *precede*, *é compatível com* e *associa-se a*. Diante de uma consulta sobre um caso clínico, o sistema recupera não apenas trechos textuais isolados, mas a estrutura relacional que conecta os dados do paciente às hipóteses diagnósticas e às condutas associadas, oferecendo ao LLM um contexto significativamente mais rico para gerar a resposta.

Adicionalmente, a representação em grafo facilita a explicabilidade. Como cada resposta gerada está vinculada a um subgrafo específico, é possível apresentar ao usuário as evidências que levaram à conclusão proposta, em forma de citações estruturadas ou de visualizações do percurso percorrido — característica especialmente valiosa em medicina.

2.6 Bancos de Dados Orientados a Grafos e o Neo4j

Os bancos de dados orientados à grafo exigem um sistema que é capaz de armazenar e modelar nativamente entidades e relações. Bancos de dados orientados a grafos, em oposição aos relacionais e aos documentais, foram projetados para esse fim. Entre os

representantes mais consolidados desse paradigma encontra-se o Neo4j, escolhido como tecnologia de armazenamento neste trabalho.

O Neo4j adota o modelo de *property graph*, em que tanto os nós quanto as arestas podem possuir rótulos e propriedades. Consultas são expressas em *Cypher*, uma linguagem declarativa cuja sintaxe é especialmente adequada para descrever padrões em grafos. Para o sistema proposto, a toxoplasmose congênita é modelada como um *property graph* cujos nós representam classes como *Exame*, *Achado Clínico*, *Diagnóstico*, *Conduta Terapêutica* e *Diretriz*, e cujas arestas codificam a semântica do raciocínio clínico. O modelo final do banco de dados armazenará as informações que o Large Language model irá recuperar através de queries no Neo4j.

2.7 Trabalhos Correlatos

A literatura registra diferentes abordagens computacionais para apoio ao diagnóstico de toxoplasmose congênita. Estratégias baseadas em sistemas especialistas e regras parametrizadas têm sido propostas como mecanismos de padronização de condutas, tipicamente operando sobre exames laboratoriais estruturados e devolvendo recomendações segundo árvores de decisão pré-definidas. Tais sistemas oferecem alta interpretabilidade, mas pecam pela rigidez: novas evidências exigem reescrita explícita das regras, e a interação tende a ocorrer por formulários, não por linguagem natural.

Em paralelo, na linha mais geral de assistentes médicos baseados em LLMs, trabalhos recentes têm explorado o uso de RAG para basear respostas em literatura biomédica especializada. Essas tendências demonstram que a combinação de modelos generativos com mecanismos de recuperação é uma direção promissora, mas a maior parte das implementações ainda se baseia em RAG vetorial, sem explorar o potencial dos grafos de conhecimento.

O presente trabalho se situa na interseção dessas duas linhas: herda dos sistemas especialistas o compromisso com a transparência e a fundamentação em diretrizes clínicas explícitas, materializadas no grafo Neo4j; e incorpora os ganhos de fluidez e generalização dos LLMs modernos, refinados por *Fine-Tuning* para o domínio da toxoplasmose congênita e orquestrados por GraphRAG.

2.8 Síntese da Revisão

A revisão consolidou os fundamentos teóricos do sistema. A discussão clínica estabeleceu por que o diagnóstico da toxoplasmose congênita é problema apropriado para uma ferramenta computacional de apoio: doença com epidemiologia relevante no Brasil, manejo complexo e distribuição desigual de *expertise*. A discussão sobre LLMs mostrou

que esses modelos, isolados, não são adequados para tarefas médicas críticas que exigem alta acurácia, sendo necessário combiná-los com técnicas de adaptação e mecanismos de recuperação. O *Fine-Tuning*, e em particular sua variante *Parameter-Efficient* (LoRA), foi caracterizado como o instrumento que alinha o modelo ao vocabulário e ao formato de resposta do domínio; o RAG, por sua vez, como o mecanismo que injeta conhecimento factual rastreável no *prompt*. A extensão GraphRAG sobre Neo4j, por fim, atende à natureza relacional do raciocínio clínico em toxoplasmose congênita e recupera relações entre nós do banco de dados baseado em grafos, relações que são perdidas em modelos baseados em vetores (vector databases). O capítulo seguinte descreve como esses fundamentos foram materializados na arquitetura e nos procedimentos de implementação do IA-Toxo.

3 Metodologia

Este capítulo descreve os materiais e métodos empregados no desenvolvimento do IA-Toxo, o assistente virtual baseado em GraphRAG para apoio ao diagnóstico de toxoplasmose congênita. A apresentação é organizada de forma a cobrir os componentes técnicos do sistema, como a modelagem do conhecimento clínico no banco de dados em grafos e a implantação da infraestrutura em ambiente de produção.

3.1 Visão Geral da Arquitetura do Sistema

A arquitetura do sistema foi criada para atender simultaneamente a dois requisitos que são conflitantes: (i) a precisão clínica das respostas, que demanda o acoplamento do modelo de linguagem a uma base de conhecimento determinística e estruturada; e (ii) a segurança da infraestrutura, que exige o isolamento rigoroso entre a rede hospitalar e os ambientes de inferência em nuvem.

Para conciliar esses requisitos, o sistema adota uma topologia em três camadas. A primeira camada é composta pela interface *frontend*, executada nos dispositivos dos profissionais de saúde no ambiente hospitalar. A segunda camada é formada pelo servidor *backend*, responsável por orquestrar o fluxo de dados: recebe a consulta do profissional, executa o *retrieval* no banco de grafos Neo4j, constrói o *prompt* aumentado e também encaminha a requisição ao serviço de inferência de LLM. A terceira camada é dada pelos serviços de inferência em nuvem, hospedados em ambientes isolados por *Virtual Private Servers* (VPS) e protegidos por regras de *firewall* e restrições de rede.

Essa separação de arquiteturas garante que dados sensíveis do paciente nunca trafeguem diretamente para a nuvem sem passar pelos mecanismos de sanitização e controle de acesso implementados no servidor *backend*. A escolha de GraphRAG como mecanismo de recuperação, ao contrário do RAG tradicional, é justificada pela natureza relacional do raciocínio diagnóstico em toxoplasmose congênita: o diagnóstico depende da articulação explícita entre sorologia materna, achados neonatais, período gestacional e condutas terapêuticas, relações que a recuperação por similaridade de *embeddings* tende a perder (LEE et al., 2025; MORE, 2025).

3.2 Construção da Ontologia Médica e do Grafo de Conhecimento

A base de conhecimento do IA-Toxo é representada como um *property graph* no Neo4j. Sua construção envolve duas etapas principais: a definição formal das entidades

e relacionamentos relevantes para o domínio clínico e a implementação desse modelo no banco de dados com os dados extraídos de diretrizes médicas e literatura especializada.

3.2.1 Definição das Entidades e Relacionamentos

A modelagem da ontologia é guiada pelos critérios diagnósticos estabelecidos nas diretrizes brasileiras e internacionais para toxoplasmose congênita. Com base nessa literatura, são identificadas as classes de nós e as relações semânticas que estruturam o raciocínio clínico no domínio.

As classes de nós definidas no grafo são:

- **Exame:** representa exames laboratoriais e de imagem, como sorologia IgM materna, teste de avididade de IgG, PCR do líquido, ultrassonografia fetal e tomografia computadorizada de crânio.
- **Achado Clínico:** representa manifestações clínicas observáveis, como hidrocefalia, calcificações intracranianas, retinocoroidite ativa e déficit neurológico.
- **Diagnóstico:** representa os possíveis desfechos diagnósticos, como toxoplasmose congênita confirmada, toxoplasmose congênita provável e infecção materna sem transmissão vertical comprovada.
- **Conduta Terapêutica:** representa as intervenções recomendadas, como sulfadiazina, pirimetamina, ácido fólico e corticoterapia.
- **Diretriz:** representa os protocolos clínicos de referência que fundamentam as recomendações do sistema.
- **Variável Temporal:** representa marcos temporais relevantes ao diagnóstico, como trimestre gestacional de infecção materna e idade gestacional ao diagnóstico.
- **Perfil Sorológico:** representa combinações de resultados sorológicos com interpretação clínica associada.

As relações semânticas que conectam esses nós são definidas para codificar explicitamente a lógica do raciocínio clínico:

- **INDICA:** conecta um Exame ou Achado Clínico a um Diagnóstico que ele sugere.
- **CONTRAINDICA:** conecta um achado clínico a uma Conduta Terapêutica que deve ser evitada em sua presença.
- **PRECEDE:** conecta uma Variável Temporal a um Exame ou Achado Clínico, codificando sequências temporais relevantes.

- **COMPATÍVEL_COM**: conecta um Perfil Sorológico a um Diagnóstico compatível.
- **RECOMENDA**: conecta um Diagnóstico à Conduta Terapêutica indicada.
- **FUNDAMENTA**: conecta uma Diretriz a um Diagnóstico ou Conduta Terapêutica que ela sustenta.
- **ASSOCIA_SE_A**: conecta entidades com relação de associação clínica sem implicação causal direta.

Essa estrutura permite ao sistema, diante de uma consulta sobre um caso clínico, recuperar não apenas informações isoladas, mas o subgrafo que conecta os dados do paciente às hipóteses diagnósticas e às condutas recomendadas, oferecendo ao modelo de linguagem um contexto relacional completo. Em experimentos comparativos, arquiteturas GraphRAG sobre Neo4j demonstraram eliminação total de alucinações e ganho de 14,3 pontos percentuais em acurácia bruta frente ao RAG vetorial equivalente (LEE et al., 2025).

3.2.2 Implementação no Neo4j

O grafo de conhecimento é persistido no Neo4j, banco de dados orientado a grafos que adota o modelo de *property graph* com consultas em linguagem *Cypher*. A escolha do Neo4j é motivada por tres fatores: a maturidade da plataforma para representação de ontologias médicas complexas, a expressividade da linguagem *Cypher* para consultas relacionais e a disponibilidade de integrações nativas com *frameworks* de orquestração de LLMs como o LangChain.

A carga inicial do grafo é realizada por meio de *scripts* de importação que processam as diretrizes médicas estruturadas e populam os nós e arestas com suas propriedades. Cada nó do tipo *Exame*, por exemplo, armazena propriedades como nome, unidade de medida, valores de referência e notas de interpretação clínica. Cada aresta do tipo *INDICA* armazena propriedades como grau de evidência, fonte bibliográfica e condições de aplicabilidade.

3.3 Pipeline GraphRAG: Recuperação e Geração

O *pipeline* GraphRAG do IA-Toxo é implementado em três estágios sequenciais, seguindo da arquitetura proposta por Lee et al. (2025): (1) tradução da consulta em linguagem natural para uma *query* Cypher, (2) execução da *query* no Neo4j e construção do *prompt* aumentado, e (3) geração da resposta pelo modelo de linguagem.

3.3.1 Tradução de Consultas para Cypher via LangChain

O primeiro estágio do *pipeline* é responsável por converter a pergunta do profissional de saúde, expressa em linguagem natural, em uma *query* Cypher executável no Neo4j. Essa conversão é mediada pelo *framework* LangChain, que expõe uma cadeia especializada para geração de *queries* em bancos de dados em grafos.

O processo ocorre da seguinte forma: o *prompt* do usuário é encapsulado em um *template* de instrução que fornece ao LLM o esquema do grafo — as classes de nós, os tipos de relacionamento e as propriedades disponíveis — e solicita a geração da *query* Cypher correspondente. O LLM, refinado para o domínio médico conforme descrito na Seção 3.4, interpreta a intenção clínica da consulta e produz uma *query* estruturada que captura as relações relevantes no grafo.

3.3.2 Recuperação de Subgrafos e Enriquecimento do Prompt

O segundo estágio executa a *query* Cypher no Neo4j e processa os resultados. O retorno do banco de dados não é uma lista plana de documentos, como no RAG vetorial, mas um subgrafo estruturado contendo nós e arestas contextualmente relevantes para a consulta. Esse subgrafo é armazenado em um formato textual que preserva a estrutura relacional e é incorporado ao *prompt* final como contexto.

O *prompt* aumentado enviado ao LLM contém três componentes: (i) a instrução de sistema, que define o papel do assistente, o seu comportamento e os critérios de formatação da resposta; (ii) o contexto recuperado do grafo, serializado com os nós, propriedades e relações relevantes; e (iii) a pergunta original do usuário. Essa estrutura garante que a resposta gerada esteja fundamentada no conhecimento validado do grafo, reduzindo o risco de alucinações para fatos clínicos específicos. De acordo com More (2025), as arquiteturas que combinam recuperação estruturada com geração condicionada reduzem a taxa de alucinação de 36% — valor típico de LLMs sem mecanismo de recuperação — para valores inferiores a 12%.

3.3.3 Geração da Resposta pelo Modelo de Linguagem

O terceiro estágio submete o *prompt* aumentado ao modelo de linguagem e processa a resposta gerada. O LLM produz uma resposta estruturada contendo, quando aplicável: hipótese diagnóstica principal, justificativa baseada nas informações da base de dados baseada em grafos.

A resposta é então retornada ao *frontend* acompanhada dos identificadores dos nós do grafo que a fundamentam, viabilizando a rastreabilidade das afirmações clínicas — propriedade essencial para contextos de suporte à decisão médica (LEE et al., 2025).

3.4 Adaptação do Modelo de Linguagem com Fine-Tuning e LoRA

O IA-Toxo utiliza um modelo de linguagem de grande porte submetido a refinamento supervisionado com o método LoRA, conforme fundamentado na Seção 2.3 da Revisão Bibliográfica. Esta seção descreve os procedimentos específicos de seleção do modelo, curação dos dados e configuração do treinamento.

3.4.1 Seleção do Modelo Base

A seleção do modelo base é orientada por três critérios: desempenho em tarefas de compreensão e geração de texto em língua portuguesa, viabilidade de implantação em ambiente com restrições de hardware e disponibilidade sob licença compatível com uso acadêmico. Modelos da família LLaMA foram considerados candidatos prioritários em razão de sua arquitetura *Transformer* (VASWANI et al., 2017), desempenho competitivo em *benchmarks* de raciocínio clínico e disponibilidade para refinamento com PEFT.

A arquitetura *Transformer*, introduzida por Vaswani et al. (2017), eliminou a dependência de redes recorrentes ao substituir a propagação sequencial por mecanismos de auto-atenção (*self-attention*). Nessa arquitetura, cada posição da sequência de entrada computa representações ponderadas pela relevância de todas as outras posições, capturando dependências de longo alcance de forma paralela. A função de atenção é formulada como:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3.1)$$

onde Q , K e V são as matrizes de consultas (*queries*), chaves (*keys*) e valores (*values*), respectivamente, e d_k é a dimensão das chaves, utilizada como fator de escala para estabilizar os gradientes durante o treinamento (VASWANI et al., 2017). Essa arquitetura, escalada para bilhões de parâmetros, constitui a base dos modelos de linguagem modernos empregados neste trabalho.

3.4.2 Curação do Conjunto de Dados de Fine-Tuning

O conjunto de dados de refinamento é composto por pares no formato [*caso clínico, conduta esperada*], elaborados em colaboração com a equipe médica de curadoria. Cada instância de treinamento contém: (i) a descrição textual de um caso clínico com dados de sorologia materna, achados neonatais e contexto gestacional; (ii) a hipótese diagnóstica correta; (iii) a justificativa clínica baseada nas diretrizes vigentes; e (iv) a conduta terapêutica recomendada.

O conjunto de dados passa por um conjunto de especialistas médicos que revisam cada instância para garantir precisão clínica e coerência com as diretrizes brasileiras e internacionais.

3.4.3 Configuração do LoRA e Procedimento de Treinamento

O refinamento é realizado com o método LoRA (HU et al., 2021), que congela os pesos originais do modelo e adiciona adaptadores de baixo *rank* r às matrizes de atenção. A variação dos pesos induzida pelo refinamento é decomposta em duas matrizes de baixa dimensionalidade $A \in R^{d \times r}$ e $B \in R^{r \times k}$, com $r \ll \min(d, k)$, de modo que a atualização efetiva é $\Delta W = BA$. Apenas essas matrizes são atualizadas durante o treinamento, mantendo os pesos originais congelados (HU et al., 2021).

3.5 Topologia de Rede e Segurança

A segurança da infraestrutura é um requisito de primeira ordem em sistemas de suporte à decisão clínica. A topologia de rede do IA-Toxo foi projetada para garantir isolamento entre zonas de confiança distintas, seguindo o princípio de mínimo privilégio.

3.5.1 Zonas de Proteção e Isolamento de Sub-redes

A rede é segmentada em três zonas com políticas de acesso distintas. A **Zona Hospitalar** (*trust zone*) abriga os dispositivos dos profissionais de saúde e o banco de dados Neo4j. Nessa zona, o tráfego interno é irrestrito, mas o acesso externo é bloqueado por padrão. A **Zona Intermediária** (*DMZ*) abriga o servidor *backend* orquestrador, que é o único ponto de comunicação entre a rede hospitalar e a nuvem. A **Zona de Nuvem** (*cloud zone*) abriga os serviços de inferência de LLM em VPS, isolados por *firewalls* com regras de *allowlist* que permitem conexões exclusivamente originadas no servidor *backend*.

3.5.2 Servidor Backend como Orquestrador

O servidor *backend* é o componente central da arquitetura de segurança e o orquestrador de toda a lógica de negócio do sistema. Ele expõe uma API REST para o *frontend*, recebe os *prompts* dos profissionais, executa o *pipeline* GraphRAG — consulta ao Neo4j, enriquecimento do *prompt* e envio ao LLM — e devolve as respostas estruturadas.

O servidor implementa controle de acesso baseado em papéis (*role-based access control*, RBAC), registro de auditoria de todas as consultas e respostas e limites de taxa (*rate limiting*) para prevenir uso abusivo do sistema.

4 Resultados e Discussão

4.1 Seção 3.1

4.2 Seção 3.2

5 Conclusões

5.1 Seção 4.1

5.2 Seção 4.2

Referências

- ABDENNEBI, A. et al. Sec-Llama: a compact fine-tuned LLM for network intrusion detection in Kubernetes clusters. In: IEEE. *Proceedings of the IEEE International Conference on Machine Learning for Communication and Networking (ICMLCN)*. [S.l.], 2025. Citado na página 39.
- ALAMMAR, J.; GROOTENDORST, M. *Hands-On Large Language Models: Language Understanding and Generation*. Sebastopol, CA: O'Reilly Media, 2024. Citado 7 vezes nas páginas 25, 26, 27, 28, 29, 30 e 40.
- DETTMERS, T. et al. QLoRA: Efficient finetuning of quantized LLMs. *arXiv preprint arXiv:2305.14314*, 2023. Citado na página 28.
- HU, E. J. et al. LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021. Citado 3 vezes nas páginas 27, 28 e 40.
- KOUACH, M. et al. Implementing machine learning models in a Kubernetes cluster for a smart monitoring system. In: IEEE. *Proceedings of the International Conference on Optimization and Applications (ICOA)*. [S.l.], 2025. Citado 2 vezes nas páginas 41 e 42.
- LEE, J. et al. GraphRAG-based question answering for battlefield situation analysis from simulation logs. In: IEEE. *Proceedings of the International Conference on ICT Convergence (ICTC)*. [S.l.], 2025. Citado 4 vezes nas páginas 35, 37, 38 e 39.
- LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2020. v. 33, p. 9459–9474. Citado 2 vezes nas páginas 29 e 30.
- MORE, R. A unified evaluation framework for grounded LLM architectures: Comparative analysis of RAG, Self-RAG and Agentic RAG. In: IEEE. *Proceedings of the International Conference on Artificial Intelligence and Signal Processing (AISP)*. [S.l.], 2025. Citado 3 vezes nas páginas 35, 38 e 43.
- VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. v. 30, p. 5998–6008. Citado 2 vezes nas páginas 39 e 40.