

Arthur Felipe Reis Souza

**Desenvolvimento de um Assistente Virtual
Baseado em GraphRAG para Auxílio no
Diagnóstico de Toxoplasmose Congênita**

Belo Horizonte

2026

Arthur Felipe Reis Souza

Desenvolvimento de um Assistente Virtual Baseado em GraphRAG para Auxílio no Diagnóstico de Toxoplasmose Congênita

Monografia apresentada durante o Seminário dos Trabalhos de Conclusão do Curso de Graduação em Engenharia Elétrica da UFMG, como parte dos requisitos necessários à obtenção do título de Engenheiro Eletricista.

Universidade Federal de Minas Gerais – UFMG

Escola de Engenharia

Curso de Graduação em Engenharia Elétrica

Orientador: Prof. Cristiano Leite de Castro

Belo Horizonte

2026

*À criança que sonhava em ser cientista
e ao adulto que aprendeu a construir o futuro.*

Agradecimentos

Agradeço de coração à minha mãe, Denise, e aos meus irmãos, Marcio, Marco e Ana Flavia, por sempre me apoiarem e serem a minha base.

Agradeço também à todas as pessoas próximas e amigos que fizeram parte da minha história e me ajudaram a chegar até aqui.

*“A inteligência artificial não precisa ser fria e impessoal.
Ela pode ser a ferramenta mais poderosa que já criamos
para entender e melhorar a condição humana.”
(Fei-Fei Li)*

Resumo

O diagnóstico da toxoplasmose congênita é um processo clínico desafiador que exige a análise rigorosa de variáveis temporais e patológicas, como exames sorológicos e achados ultrassonográficos. O uso de Large Language Models (LLMs) na medicina, embora promissor, enfrenta obstáculos relacionados à imprecisão (alucinações do modelo) e à necessidade de isolamento de dados sensíveis. Sendo assim, este trabalho de conclusão tem como objetivo desenvolver uma arquitetura de chatbot baseado nas técnicas de *Fine-Tuning* e *Graph Retrieval-Augmented Generation* (GraphRAG) para auxiliar médicos e enfermeiros. A metodologia engloba a estruturação de uma ontologia médica em um banco de dados orientado a grafos (Neo4j) e a concepção de uma topologia de rede segura, que irá restringir o acesso de forma a proteger a rede interna do sistema como também os clientes. O sistema utiliza um servidor *backend* intermediário atuando como orquestrador, isolando a rede hospitalar dos ambientes de inferência de modelos hospedados em nuvem. Como resultados, nota-se que a orquestração via GraphRAG aumenta a acurácia e a explicabilidade dos resultados gerados, mitigando riscos clínicos ao fundamentar as respostas estritamente na literatura médica validada no grafo. Conclui-se que a separação arquitetural, aliada a bases de dados relacionais avançadas e técnicas de refinamento de modelo, viabiliza o uso da IA generativa de forma segura e eficiente nos ecossistemas fechados de saúde.

Palavras-chave: toxoplasmose congênita. inteligência artificial. GraphRAG. banco de dados em grafos. segurança da informação.

Abstract

The diagnosis of congenital toxoplasmosis is a challenging clinical process that requires rigorous analysis of temporal and pathological variables, such as serological tests and ultrasound findings. The use of Large Language Models (LLMs) in medicine, while promising, faces obstacles related to inaccuracy (model hallucinations) and the need to isolate sensitive data. Therefore, this final graduation project aims to develop a chatbot architecture based on Fine-Tuning and Graph Retrieval-Augmented Generation (GraphRAG) techniques to assist doctors and nurses in decision support. The methodology includes structuring a medical ontology in a graph database (Neo4j) and designing a secure network topology, aiming to restrict access to protect the system's internal infrastructure and user privacy. The system uses an intermediary backend server acting as an orchestrator, isolating the hospital network from cloud-hosted model inference environments. As a result, it is observed that GraphRAG orchestration increases the accuracy and explainability of the generated outcomes, mitigating clinical risks by grounding responses strictly in validated medical literature within the graph. It is concluded that architectural separation, combined with advanced relational databases and refinement techniques, enables the secure and efficient use of generative AI in closed healthcare ecosystems.

Key-words: congenital toxoplasmosis. artificial intelligence. GraphRAG. graph databases. information security.

Lista de ilustrações

Lista de tabelas

Lista de abreviaturas e siglas

API	Application Programming Interface
HF	Hugging Face
IA	Inteligência Artificial
LLM	Large Language Model
RAG	Retrieval-Augmented Generation
REST	Representational State Transfer
UI	User Interface
VNet	Virtual Network
VPS	Virtual Private Server

Lista de símbolos

G	Símbolo placeholder
-----	---------------------

Sumário

1	INTRODUÇÃO	21
1.1	Contextualização e Justificativa	21
1.2	Definição do Problema	21
1.3	Objetivos	22
1.3.1	Objetivo Geral	22
1.3.2	Objetivos Específicos	22
1.4	Estrutura Geral do Trabalho	23
2	METODOLOGIA	25
2.1	Seção 2.1	25
2.2	Seção 2.2	25
3	RESULTADOS E DISCUSSÃO	27
3.1	Seção 3.1	27
3.2	Seção 3.2	27
4	CONCLUSÕES	29
4.1	Seção 4.1	29
4.2	Seção 4.2	29

1 Introdução

1.1 Contextualização e Justificativa

A integração de sistemas baseados em Inteligência Artificial (IA) no ambiente hospitalar tem transformado as metodologias de suporte à tomada de decisão, oferecendo ferramentas avançadas que processam um grande volume de dados e retornam uma resposta. Neste caso, o diagnóstico da toxoplasmose congênita traz grandes desafios, pois identificar precisamente essa patologia exige a relação de variáveis temporais e clínicas, como a análise de perfis sorológicos maternos (testes de avididade, níveis de IgG e IgM), o período gestacional e também a interpretação de exames complexos, como o de ultrassonografia. Para médicos e enfermeiros, processar todos esses dados relacionais com diretrizes médicas atualizadas, frequentemente sob a pressão do fluxo hospitalar, é uma tarefa demandante e de alta exigência cognitiva.

O desenvolvimento de sistemas de engenharia aplicados à saúde exige não apenas precisão algorítmica, precisa também infraestruturas que garantam a segurança dos dados, respeitando rigorosos fluxos de trabalho clínicos e normas de privacidade. Tradicionalmente, Large Language Models (LLMs) apresentam os riscos de cometer "alucinações", que é quando o modelo gera orientações plausíveis, porém que são clinicamente imprecisas. Para mitigar esse risco de alucinações e justificar a viabilidade técnica e científica de um assistente virtual médico, é necessário a construção de uma arquitetura robusta que ligue o raciocínio do modelo em bases de conhecimento determinísticas e estruturadas dentro de uma rede privada.

1.2 Definição do Problema

O problema central abordado neste trabalho se dá na limitação das técnicas tradicionais de recuperar informações complexas, como o *Retrieval-Augmented Generation* (RAG) que faz a busca de informações linearmente nas bases de dados comumente chamadas de *embedding databases*. Outro obstáculo se dá em mapear e recuperar adequadamente as conexões causais e temporais no diagnóstico da toxoplasmose congênita. A questão principal deste trabalho é: como arquitetar e desenvolver um sistema de *chatbot* que compreenda a complexa ontologia dessa doença utilizando técnicas de Deep Learning como *graphRAG* e *Fine-Tuning*, ao mesmo tempo em que garante o isolamento seguro entre a rede hospitalar e os ambientes de inferência de IA em nuvem?

Para solucionar essa lacuna técnica, este trabalho propõe a implementação de uma

arquitetura de chatbot baseada na integração das técnicas de *Graph Retrieval-Augmented Generation* (GraphRAG) e *Fine-tuning*. Através da modelagem da base de dados do conhecimento clínico em um banco de dados orientado a grafos (Neo4j), o sistema torna-se capaz de mapear explicitamente as ligações entre sintomas, testes laboratoriais e intervenções terapêuticas. A solução projetada utiliza um servidor *backend* intermediário que atua como orquestrador, isolando a rede hospitalar dos ecossistemas de modelos hospedados em nuvem, que são protegida por firewalls e serviços de restrições de redes, assegurando a proteção de dados sensíveis e a acurácia do contexto injetado nas requisições.

1.3 Objetivos

Os objetivos deste trabalho estão divididos de forma a guiar o desenvolvimento e a avaliação do software proposto.

1.3.1 Objetivo Geral

Desenvolver um sistema de *chatbot* orquestrado por uma arquitetura GraphRAG com Fine-tuning para auxiliar profissionais de saúde (médicos e enfermeiros) no processo de diagnóstico da toxoplasmose congênita, garantindo a precisão da informação e a segurança da infraestrutura de rede.

1.3.2 Objetivos Específicos

- Projetar uma topologia de rede segura, estabelecendo zonas de proteção e regras de sub-redes para mediar a comunicação entre o ambiente hospitalar, o servidor *frontend/backend* e a nuvem.
- Modelar uma ontologia clínica para a toxoplasmose congênita e estruturá-la em um banco de dados em grafos (Neo4j).
- Realizar o refinamento do modelo usando uma base de dados propriamente curada e refinada de diagnósticos da doença.
- Desenvolver uma API *backend* responsável por receber o *prompt* inicial, executar o *retrieval* no banco de grafos e construir o *prompt* aumentado.
- Integrar a infraestrutura de orquestração com serviços de inferência de LLMs em nuvem, garantindo a sanitização e o fluxo adequado dos dados.
- Desenvolver uma interface *frontend* otimizada para a interação e visualização de dados por parte dos profissionais clínicos.

1.4 Estrutura Geral do Trabalho

Para atingir os objetivos propostos de forma clara e progressiva, esta monografia está estruturada em seis capítulos. O Capítulo 2 apresenta a Revisão de Literatura, analisando o estado da arte referente a arquiteturas RAG, bancos de dados em grafos e a aplicação de IA em fluxos de diagnóstico médico. O Capítulo 3 descreve os Materiais e Métodos, detalhando a engenharia de *software* e *hardware*, o modelo do banco Neo4j, como realizar a técnica de Fine-Tuning do modelo e também as políticas de segurança de rede e a integração de APIs. O Capítulo 4 expõe os Resultados, relatando o comportamento do sistema e o desempenho do modelo na geração de diagnósticos utilizando métricas nebulosas (métricas Fuzzy). O Capítulo 5 traz a Discussão, promovendo uma análise crítica da arquitetura proposta frente às soluções tradicionais de mercado. Finalmente, o Capítulo 6 apresenta a Conclusão do estudo, destacando as contribuições obtidas e sugerindo evoluções futuras para o projeto.

2 Metodologia

2.1 Seção 2.1

2.2 Seção 2.2

3 Resultados e Discussão

3.1 Seção 3.1

3.2 Seção 3.2

4 Conclusões

4.1 Seção 4.1

4.2 Seção 4.2